LABORATUVAR 7 · GENEL SÜRÜM · Şişeleme Hattı

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad 230541134
Muhammed Sıddık Karabulut

Grup

Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Kritik kusurlar bağımsız ikinci kontrol veya insan onayıyla denetlenmelidir. Hata tespit edilirse ilgili şişeler ayrılıp yeniden incelenmelidir. YZ'nin yanlış kararı, robotun emniyet sınırlarını aşmasına neden olmamalıdır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Kritik kusurlar bağımsız ikinci kontrol veya insan onayıyla denetlenmelidir. Hata tespit edilirse ilgili şişeler ayrılıp yeniden incelenmelidir. YZ'nin yanlış kararı, robotun emniyet sınırlarını aşmasına neden olmamalıdır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşik, doğrulama testleri ve kabul edilebilir kusur kaçırma oranına göre belirlenmelidir. Eşik altında otomatik OK ve yeni robot parametresi uygulanmamalı; insan kontrolüne veya doğrulanmış alternatif işleyişe geçilmelidir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Bağımsız ikinci kontrol, hatalı ürünleri ayırma ve insan incelemesi — **monitoring / human override**
Girdi manipüle edildi	Otomatik kararı engelleme; manuel kontrol veya kontrollü duruş — **fail-safe / fallback**
Confidence düştü	Eşik altında karar vermeme; insana yönlendirme — **confidence threshold / fallbacl**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.